

PRÁCTICO 1: TEORÍA DE LA INFORMACIÓN

CANTIDAD DE INFORMACIÓN - ENTROPÍA

1. Análisis de Capacidad e Información en Imágenes Digitales

a) Suponga una imagen de alta definición (HD) dividida en una matriz de 1920 por 1.080 píxeles. Indique la cantidad máxima teórica de información (en bits y en Megabytes) que proporciona este cuadro si está codificada en 24 bits por píxel.

La imagen tiene: $1920 \times 1080 = 2,073,600$ píxeles

1 píxel $\underline{\hspace{2cm}}$ 24 bits

$$2,073,600 \times \frac{2,073,600 \text{ píxel} \times 24 \text{ bits}}{1 \text{ píxel}} = 49,766,400 \text{ bits}$$

* Byte

8 bits. $\underline{\hspace{2cm}}$ 1 byte

$$49,766,400 \times \frac{49,766,400 \text{ bits} \times 1 \text{ byte}}{8 \text{ bits}} = 6,220,800 \text{ byte}$$

* Megabyte: Sistema Binario

1 byte $\underline{\hspace{2cm}}$ 2^{20} MB

$$6,220,800 \text{ byte} \times \frac{6,220,800 \text{ byte}}{2^{20} \text{ MB}} = 5,9326 \text{ MB}$$

b) Luego, considere una imagen en resolución 4K (3840 x 2160 píxeles). ¿Cuánta información máxima se genera si se codifica en formato HDR (High Dynamic Range) utilizando 10 bits por cada canal de color (Rojo, Verde y Azul)?

La imagen tiene $3840 \times 2160 = 8,294,400$ píxeles

1 píxel $\underline{\hspace{2cm}}$ 30 bits

$$8,294,400 \text{ píxeles} \times 30 \text{ bits} = 248,832,000 \text{ bits}$$

* Megabyte: Sistema Binario

$$248,832,000 \text{ bits} \times \frac{1 \text{ byte}}{8 \text{ bits}} \times \frac{1 \text{ MB}}{2^{20} \text{ byte}} = 29,66 \text{ MB}$$

* Megabyte: Sistema decimal

$$248,832,000 \text{ bits} \times \frac{1 \text{ byte}}{8 \text{ bits}} \times \frac{1 \text{ MB}}{10^6 \text{ byte}} = 31,104 \text{ MB}$$

c) Análisis teórico: La cantidad de información calculada en los incisos anteriores, ¿representa la información "real" (Entropía) de una fotografía o únicamente su capacidad máxima de almacenamiento? Justifique su respuesta explicando el concepto de redundancia espacial.

Los cálculos anteriores representan la capacidad máxima teórica de almacenamiento sin compresión. La entropía real de una foto es mucho menor debido a la redundancia espacial: los píxeles vecinos suelen tener colores casi idénticos (cielo, paredes, sombras), por lo que transmiten poca información nueva.

2. Cantidad de Información en Modelos de Predicción de Texto

Un sistema de autocompletado en un dispositivo móvil debe predecir la siguiente palabra . que escribirá un usuario.

a) Si el vocabulario total del diccionario del sistema es de 15.000 palabras y, al iniciar una frase, el sistema asume a priori que cualquier palabra es equiprobable, ¿cuánta información (en bits) se genera al elegir una palabra exacta?

$$I = -\log_2 \left(\frac{1}{15000} \right) = 13.87 \text{ bits}$$

Define la cantidad de información individual:

en bits

$$\rightarrow I_i = \log_r \left(\frac{1}{P_i} \right)$$

Rta: Adivinar la palabra correcta entre 15.000 posibles te aporta 13.87 bits de información

b) Suponga que, analizando el contexto de las palabras anteriores, un modelo de Inteligencia Artificial determina que solo hay 5 palabras lógicas posibles para continuar la frase, siendo estas 5 opciones equiprobables. ¿Cuánta información se genera ahora al confirmar cuál de esas 5 es la palabra correcta?

$$I = -\log_2 \left(\frac{1}{5} \right) = 2.32 \text{ bits}$$

Rta: Adivinar la palabra correcta entre 5 posibles te aporta 2.32 bits de información

c) ¿Qué cantidad de información (en bits) aportó el contexto procesado por la Inteligencia Artificial al sistema? Explique qué significa este valor en términos de incertidumbre.

Reducción de incertidumbre $I = \log_2 \left(\frac{15000}{5} \right) = 11.55 \text{ bits}$

$$\Delta I = I_{\text{inicial}} - I_{\text{final}} = \log_2(15.000) - \log_2(5) = \log_2 \left(\frac{15.000}{5} \right)$$

$$13.87 - 2.32 = 11.55 \text{ bits}$$

$$I = \log_2 \left(\frac{\text{Rango de incertidumbre ANTES}}{\text{Rango de incertidumbre DESPUÉS}} \right)$$

El contexto procesado por la Inteligencia Artificial aportó 11.55 bits de información. Esto significa que redujo la incertidumbre del sistema, ya que pasó de tener 15.000 palabras /posibles a solamente 5 opciones posibles.

3. Propiedades Matemáticas de la Información

a) Demostrar las siguientes igualdades correspondientes a la propiedad de cambio de base de los logaritmos:

$$\log_a x = \frac{\log_b x}{\log_b a} = \log_a b \cdot \log_b x$$

Demostración

$$\log_a x = \frac{\log_b x}{\log_b a} = \log_a b \cdot \log_b x$$

$$X = b^{\log_b(x)}$$

$$\log_a(x) = \log_a(b^{\log_b(x)})$$

$$\log_a(x) = \log_b(x) \cdot \log_a(b)$$

$$\log_a(x) = \frac{\log_b(x)}{\log_b(a)}$$

b) Justificación Teórica: Indique en qué situaciones prácticas de la Teoría de la Información resulta indispensable utilizar esta propiedad de cambio de base (Pista: Relacione este concepto con las unidades de medida de la información).

La propiedad de cambio de base resulta indispensable en Teoría de la Información cuando necesitamos expresar la cantidad de información utilizando diferentes unidades de medida: base 2 para bits, base e para nats o base 10 para hartleys.

4. Entropía en Sistemas de Reconocimiento Automático

En el desarrollo de un modelo de Machine Learning para la traducción automatizada, el sistema debe clasificar 5 configuraciones básicas (c_1, c_2, c_3, c_4, c_5). Tras analizar un corpus de datos, se determina que la configuración c_1 es la más frecuente, con una probabilidad $p_1 = 1/3$, mientras que las otras cuatro configuraciones son equiprobables $p = 1/6$ cada una.

a) Calcula la cantidad de información individual que aporta la detección de cada configuración.

$$c_1 = p_1 = \frac{1}{3}$$

$$c_2, c_3, c_4, c_5 \rightarrow p = \frac{1}{6}$$

$$I_1 = -\log_2\left(\frac{1}{3}\right) = 1.585 \text{ bits de información}$$

$$I_2 = I_3 = I_4 = I_5 = -\log_2\left(\frac{1}{6}\right) = 2.585 \text{ bits de información}$$

Fórmula Información individual

$$I_i = \log_2\left(\frac{1}{P_i}\right) = -\log_2(P_i)$$

b) Calcula la entropía total de esta fuente de información.

$$H(x) = \sum_{i=1}^n P_i \cdot \log_2 \left(\frac{1}{P_i} \right)$$

$$H(x) = P(c_1) \cdot I(c_1) + P(c_2) \cdot I(c_2) + P(c_3) \cdot I(c_3) + P(c_4) \cdot I(c_4) + P(c_5) \cdot I(c_5)$$

$$H(x) = \frac{1}{3} \cdot 1,585 + \frac{1}{6} \cdot 2,585 + \frac{1}{6} \cdot 2,585 + \frac{1}{6} \cdot 2,585 + \frac{1}{6} \cdot 2,585$$

$$H(x) = 2,2516 \text{ bits/símbolo}$$

c) Si el sistema se calibra para que todas las configuraciones tengan exactamente la misma probabilidad de aparición, ¿la entropía aumentaría o disminuiría?

Justifica tu respuesta.

La entropía aumentaría. Al calibrar el sistema para que las 5 configuraciones sean equiprobables ($p = 1/5$), se alcanza la entropía máxima $H_{\max} = \log_2(5) = 2,3219$, superando los 2,2516 calculados en el inciso anterior debido a que la equiprobabilidad maximiza la incertidumbre del sistema.

5. Entropía Máxima vs. Entropía Real en un Pipeline de Datos

Un pipeline de backend clasifica las peticiones entrantes de los usuarios en 8 categorías o intenciones distintas.

a) Demuestra matemáticamente que si el balanceador de carga distribuye las peticiones de forma tal que las 8 categorías tienen exactamente la misma probabilidad de ocurrir, el sistema alcanza su máxima incertidumbre (entropía máxima). ¿Cuál es ese valor en bits?

$$H_{\max} = \log_2(8) = 3 \text{ bits}$$

Demostración

En general para n símbolos equiprobables

$$H = \log_2(n)$$

$$D = H - \log_2(n) \Rightarrow D \leq 0$$

$$H = \sum_{i=1}^n P_i \cdot \log_2 \left(\frac{1}{P_i} \right)$$

Reemplazando

$$\sum_{i=1}^n P_i \cdot \log_2 \left(\frac{1}{P_i} \right) = \log_2(n) \quad \text{como } \sum P_i = 1$$
$$\sum_{i=1}^n P_i \cdot \log_2 \left(\frac{1}{P_i} \right) = \sum_{i=1}^n P_i \log_2(n)$$

$$\sum_{i=1}^n p_i \left(\log_2 \left(\frac{1}{p_i} \right) - \log_2(n) \right) \quad \text{por cambio de base}$$

$$\frac{1}{\ln(2)} \cdot \sum_{i=1}^n p_i \cdot \ln \left(\frac{1}{n \cdot p_i} \right) \quad x = \frac{1}{n \cdot p_i} \quad y \quad \ln(x) \leq x-1$$

$$\ln \left(\frac{1}{n \cdot p_i} \right) \leq \frac{1}{n \cdot p_i} - 1$$

$$n \left(\frac{1}{n \cdot p_i} \right) \cdot p_i \leq \frac{1}{n} - p_i \quad \text{aplico sumatoria en ambos lados}$$

$$\sum_{i=1}^n p_i \cdot \ln \left(\frac{1}{n \cdot p_i} \right) \leq \sum_{i=1}^n \frac{1}{n} - p_i \rightarrow \sum_{i=1}^n p_i \cdot \ln \left(\frac{1}{n \cdot p_i} \right) \leq \sum_{i=1}^n \frac{1}{n} - \sum_{i=1}^n p_i$$

$$= \sum_{i=1}^n p_i \cdot \ln \left(\frac{1}{n \cdot p_i} \right) \leq \cancel{\frac{1}{n}} - \sum_{i=1}^n p_i \xrightarrow{=1} 1$$

$$= \sum_{i=1}^n p_i \cdot \ln \left(\frac{1}{n \cdot p_i} \right) \leq 0$$

luego $D \leq 0 \quad \therefore \quad H \leq \log_2(n) \quad \text{cqd}$

b) Al pasar el sistema a producción, se observa que el tráfico real está fuertemente sesgado, respondiendo a la siguiente distribución de probabilidades:

$$p_3 = 0.1, p_4 = 0.08, p_5 = 0.06, p_6 = 0.04, p_7 = 0.015, p_8 = 0.005.$$

Calcula la entropía real del sistema en producción.

$$p_1 = 0.5 \Rightarrow 0.5 \cdot \log_2 \left(\frac{1}{0.5} \right) = 0.5$$

$$p_2 = 0.2 \Rightarrow 0.2 \cdot \log_2 \left(\frac{1}{0.2} \right) = 0.4644$$

$$p_3 = 0.1 \Rightarrow 0.1 \cdot \log_2 \left(\frac{1}{0.1} \right) = 0.3322$$

$$p_4 = 0.08 \Rightarrow 0.08 \cdot \log_2 \left(\frac{1}{0.08} \right) = 0.2915$$

$$p_5 = 0.06 \Rightarrow 0.06 \cdot \log_2 \left(\frac{1}{0.06} \right) = 0.2435$$

$$p_6 = 0.04 \Rightarrow 0.04 \cdot \log_2 \left(\frac{1}{0.04} \right) = 0.1858$$

$$p_7 = 0.015 \Rightarrow 0.015 \cdot \log_2 \left(\frac{1}{0.015} \right) = 0.0909$$

$$p_8 = 0.005 \Rightarrow 0.005 \cdot \log_2 \left(\frac{1}{0.005} \right) = 0.0382$$

$$H = 0.500 + 0.4644 + 0.3322 + 0.2915 + 0.2435 + 0.1858 + 0.0909 + 0.0382 = 2.1465 \text{ bits}$$

c) Compara ambos resultados (inciso a vs inciso b). ¿Qué nos dice esta diferencia (caída de entropía) sobre la predictibilidad del comportamiento de los usuarios?

La entropía máxima obtenida en el inciso a) es de 3 bits, mientras que la entropía real calculada en el inciso b) es menor debido a que las probabilidades de las 8 categorías no son iguales.

Por lo tanto: $H_{\text{real}} = 2.1465 < H_{\text{max}} = 3 \text{ bits}$

Esta caída de entropía indica que el comportamiento de los usuarios es más predecible, ya que algunas intenciones aparecen con mayor frecuencia que otras.

6. Entropía Teórica vs. Redundancia en el Lenguaje

Considere un alfabeto teórico de 27 letras.

a) Calcule la cantidad de información (Entropía Máxima) que genera la elección de 1 sola letra, una secuencia de 2 letras y una secuencia de 3 letras, asumiendo a priori que todas las letras son equiprobables y la elección de cada letra es completamente independiente de las demás.

1 sola letra

$$H_{\max} = \log_2(27) = 4,755 \text{ bits}$$

2 letras

$$H_{\max} = 2 \cdot \log_2(27) = 9,510 \text{ bits}$$

3 letras

$$H_{\max} = 3 \cdot \log_2(27) = 14,265 \text{ bits}$$

b) Si pasamos de este "alfabeto teórico" al uso real del idioma español, el principio de equiprobabilidad desaparece. Explique por qué sucede esto y cómo afecta al valor de la entropía real de un carácter.

En el español real, no todas las letras aparecen con la misma frecuencia.

Por ejemplo, algunas letras como e, a, o aparecen mucho más frecuentemente que otras como x, k, w.

Por lo tanto:

$$P(e) \neq P(a) \neq P(x)$$

La entropía real se calcula mediante:

$$H(x) = \sum_{i=1}^n p_i \cdot \log_2 \left(\frac{1}{p_i} \right)$$

Como las probabilidades no son iguales, la entropía real de una letra es menor que la entropía máxima:

$$H_{\text{real}} < H_{\max} = 4,755 \text{ bits}$$

c) En el idioma español tampoco se cumple el principio de independencia (las letras están condicionadas por las anteriores). Dé un ejemplo de dependencia fuerte entre dos letras en español y explique conceptualmente qué sucede con la cantidad de información generada al leer la segunda letra.

En español existe dependencia entre las letras. Por ejemplo, después de Q generalmente aparece U. Por eso, al conocer la primera letra, disminuye la incertidumbre sobre la segunda:

$$H(X_2 | X_1) < H(X_2)$$

Entonces, la segunda letra genera menos información,

7. Computación Ternaria y Economía de la Base (Radix Economy)

En 1958, la Universidad Estatal de Moscú construyó la computadora "Setun", la cual no utilizaba lógica binaria (bits, base 2), sino lógica ternaria (trits, base 3). Los ingenieros se basaron en el teorema de la "Economía de la Base", el cual postula que el costo de hardware de un registro es proporcional a la cantidad de dígitos necesarios (I) multiplicada por los niveles de voltaje que debe distinguir cada dígito (la base b). Es decir $C = I \cdot b$

Para un sistema que debe poder representar $V = 1.000.000$ de estados diferentes:

a) Calcule cuántos "bits" () y cuántos "trits" () enteros se necesitan como mínimo. Aplique la fórmula de costo para ambos y demuestre aritméticamente cuál arquitectura es más económica.

* Lógica Binaria ($b = 2$) $\Rightarrow 2^I \geq 1.000.000$

$$I_2 = \log_2 (1.000.000) = 19,9316 \Rightarrow 20 \text{ bits}$$

$$C_2 = I_2 \cdot b_2 = 20 \times 2 = 40$$

* Lógica Ternaria ($b = 3$) $\Rightarrow 3^I \geq 1.000.000$

$$I_3 = \log_3 (1.000.000) = 12,5754 \Rightarrow 13 \text{ trits}$$

$$C_3 = I_3 \cdot b_3 = 13 \times 3 = 39$$

Comparación: Como $C_3 < C_2$ ($39 < 40$), la arquitectura ternaria es más económica.

b) Más allá de comparar base 2 y base 3, demuestre analíticamente (utilizando la primera derivada) cuál es la base teórica (número real absoluto) que minimiza la función de costo para cualquier valor de V .

Para una base cualquiera $b \Rightarrow I = \log_b(V)$

$$C(b) = b \cdot I \Rightarrow C(b) = b \cdot \log_b(V)$$

$$C(b) = b \cdot \frac{\ln(V)}{\ln(b)}$$

Como $\ln(V)$ es constante

$$C(b) = \ln(V) \cdot \frac{b}{\ln(b)}$$

$$C'(b) = \ln(V) \cdot \frac{(1 \cdot \ln(b) - b \cdot \frac{1}{b})}{(\ln(b))^2}$$

$$C'(b) = \ln(v) \cdot \frac{\ln(b) - 1}{(\ln(b))^2}$$

$$C'(b) = 0 \Rightarrow \ln(v) \cdot \frac{\ln(b) - 1}{(\ln(b))^2} = 0$$

$$\ln(v) \neq 0$$

$$(\ln(b))^2 \neq 0$$

Entonces

$$\ln(b) - 1 = 0$$

$$\ln(b) = 1$$

$$b = e^1$$

$$\ln(e) = 1$$

La base teórica que minimiza el costo es $e = 2,718$. Como en la práctica la base debe ser un número entero, las bases cercanas son 2 y 3, y la base 3 es la más cercana a e .

c) Si la base 3 es matemáticamente superior, investigue o deduzca por qué la industria global abandonó proyectos como la "Setun" y adoptó el estándar binario.

Aunque la base 3 es más eficiente matemáticamente, la industria adoptó el sistema binario porque es más sencillo implementar dos estados eléctricos (0 y 1) que tres.

Además, ya existía una gran infraestructura de hardware y software basada en binario.

8. Árboles de Decisión y Capacidad de Información .

Se tienen 12 monedas de apariencia idéntica, pero se sabe que exactamente una de ellas es falsa y tiene un peso diferente al resto (no se sabe a priori si es más pesada o más liviana). Usted dispone de una balanza de platillos clásica.

a) Sabiendo que cada pesada en la balanza (equilibrio, se inclina a la izquierda, se inclina a la derecha) genera una cierta cantidad de información, demuestre matemáticamente por qué son necesarias exactamente 3 pesadas para encontrar la moneda falsa y determinar su anomalía de peso.

1. CASOS POSIBLES

i. es mas pesada que las demás

II. es mas liviana que las demás

Calculo de estados iniciales posibles

CASOS: 12 monedas .2 estados posibles =24 CASOS POSIBLES

2. CAPACIDAD d3 información de la balanza

i. Equilibrio ambos platillos pesan lo mismo

ii. Inclinação Derecha el platillo derecho es mas pesado

iii. Inclinação Izquierda el platillo izquierdo es mas pesado

Por lo tanto el número 3 nos indica que estamos trabajando en base ternaria 3^n

3. la cantidad de hojas del árbol 3^n debe ser mayor o igual a 24 , cubra todos los casos posibles

$$3^n \geq 24$$

Probamos $\neq$ casos

Si $n=1 \Rightarrow \underset{d}{3}^1 \geq 24 \quad ? \Rightarrow 3 \neq 24 \quad \text{no sirve}$


Si $n=2 \Rightarrow \underset{d}{3}^2 \geq 24 \quad ? \Rightarrow 9 \neq 24 \quad \text{no sirve}$

Si $n=3 \Rightarrow \underset{d}{3}^3 \geq 24 \quad \Rightarrow 27 \geq 24 \quad \text{si sirve}$


Como $n=3$ nos da un valor de 27, el cual cubre todos los casos posibles, queda demostrado porque son necesarios 3 pesadas para encontrar la moneda..

b) Esquematice la metodología (el árbol de decisiones) de la primera pesada y de todas sus ramas para demostrar cómo se divide el espacio de incertidumbre respetando la base ternaria calculada.


b. 1er pesada



2da Pasada



2da pasada



9. Información y Reducción de Incertidumbre

En un programa de preguntas, el candidato debe encontrar un premio oculto detrás de una de tres puertas. El premio está detrás de cada puerta con igual probabilidad; una cabra está detrás de las otras dos puertas. Primero, el candidato elige una puerta.

a) ¿Cuál es la probabilidad de que el premio esté detrás de la puerta elegida?

Si hay 3 puertas y el premio puede estar detrás de cualquiera de ellas con igual probabilidad, entonces:

$$p = \frac{\text{puertas con premio}}{\text{puertas totales}} = \frac{1}{3}$$

b) El presentador del juego sabe detrás de qué puerta está oculto el premio. En lugar de abrir la puerta elegida, abre una de las otras dos puertas que contiene una cabra. Ahora, ofrece al candidato cambiar a la única puerta cerrada que queda. ¿Cuál es la probabilidad de ganar el premio cambiando de puerta?

Supongamos que el participante elige la puerta 1 y cambia de puerta cuando el presentador descarta una.

Premio en	Presentador descarta	Resultado
Puerta 1	puede abrir la 2 o 3 (ambas puertas)	Participante pierde
Puerta 2	Solo puede abrir la puerta 3	Participante gana
Puerta 3	Solo puede abrir la puerta 2	Participante gana

Esto es porque el presentador sabe donde esta el premio y no puede abrir la puerta elegida ni la que tiene premio. Por lo tanto:

$$p(\text{ganar cambiando}) = \frac{2}{3} \quad \text{y} \quad p(\text{ganar quedándose}) = \frac{1}{3}$$

c) Análisis de la Información: En términos de la Teoría de la Información, el estado inicial del juego posee una incertidumbre máxima. Cuando el presentador abre una puerta con una cabra, está transmitiendo un "mensaje" al candidato. Calcule la Entropía inicial del sistema y explique conceptualmente por qué la acción del presentador inyecta Información al sistema, rompiendo la equiprobabilidad.

$$\text{La Entropía inicial } H_0 = \log_2(3) = 1,585 \text{ bits}$$

Entropía luego de abrir una puerta :

$$H_1 = -\left(\frac{1}{3} \cdot \log\left(\frac{1}{3}\right) + \frac{2}{3} \cdot \log\left(\frac{2}{3}\right)\right) = 0,918 \text{ bits}$$

Información que genera el presentador

$$I = H_0 - H_1 = 1,585 \text{ bits} - 0,918 \text{ bits} = 0,667 \text{ bits}$$

Esto ocurre porque el presentador no elige una puerta al azar, su elección está condicionada por donde está el premio. Cuando el participante elige la puerta sin premio, lo que ocurre 2/3 de las veces, el presentador se ve obligado a elegir la única puerta disponible con una cabra, la cual delata la posición del premio, aumentando la probabilidad de la puerta restante de 1/3 a 2/3.